

Федеральное государственное автономное образовательное учреждение  
высшего образования «Национальный исследовательский  
Нижегородский государственный университет им. Н.И. Лобачевского»  
Институт информационных технологий, математики и механики  
Кафедра информатики и автоматизации научных исследований

УДК

№ госрегистрации

Инв. №

**УТВЕРЖДАЮ**

Профессор кафедры  
ИАНИ ННГУ, д.т.н.

\_\_\_\_\_ Н.В. Старостин  
« \_\_\_\_ » \_\_\_\_\_ 2021 г.

Научно-технический отчет

**РАЗРАБОТКА ПРОГРАММНОГО СРЕДСТВА**

**«Разработка и реализация программного обеспечения анализа  
дефектов поверхности трубопровода с использованием методов  
машинного обучения (ПО “Око Эйлера”)»**

## Содержание

Содержание	2
Введение	3
Содержательная постановка задачи	4
Входные данные	5
Выходные данные	7
[WIP: заголовок]	8
Выбор архитектуры ИНС	8
Генерация данных	8
Результаты тестирования	10
Заключение	12
Список литературы	13

## **Введение**

Рассматривается проблема разработки программного обеспечения анализа дефектов поверхности трубопровода по изображению.

В рамках данного проекта выполнены следующие работы:

1. Генерация обучающего набора данных на основе предоставленных изображений сегментов трубопровода.
2. Построение искусственной нейронной сети для выделения дефектов различных типов на изображениях разреза сегмента трубопровода.

## Содержательная постановка задачи

Рассматривается задача семантической сегментации изображения. Имеется обучающее множество пар, состоящих из изображения и маски, содержащей информацию о номере класса, соответствующего каждому пикселю изображения. Требуется построить искусственную нейронную сеть, обеспечивающую сегментацию изображения на классы, соответствующие каждому типу дефектов, таким образом, чтобы результат сегментации изображения соответствовал маске со следующими метриками: точность не ниже 75%, IoU не ниже 50%.

Под точностью подразумевается отношение числа верно классифицированных пикселей изображения к общему их числу.

Обозначим область, получившую в результате сегментации номер  $n$ , за  $N'$ . Область, имеющая номер  $n$  в маске, обозначим за  $N$ . IoU - отношение площади пересечения  $N$  и  $N'$  к площади их объединения.

## Входные данные

Входные данные считываются из файла в формате PNG. Они представляют собой RGB-изображения продольного разреза сегмента нефтепровода в спектре видимого света. Пример входных данных приведён на рисунке 1.



Рис. 1 - пример входных данных

Изображениям в обучающей выборке соответствуют маски - двумерные массивы, содержащие номер класса, соответствующего каждому пикселю изображения. Маска может быть визуализирована как чёрно-белое изображение, где разным классам соответствуют разные оттенки серого. Пример визуализации представлен на рисунке 2.



Рис. 2 - пример визуализации маски

## Выходные данные

Выходные данные представляют собой изображение в формате PNG, являющееся визуализацией результата сегментации исходного изображения. Каждому типу поверхности соответствует определённый цвет: углубление - красный, слой нефтепродуктов - синий, слой ржавчины - пурпурный, поверхность без дефектов - чёрный. Пример выходных данных приведён на рисунке 3.




Рис. 3 - пример выходных данных

## Разработка решения

### Выбор архитектуры ИНС

Существует множество архитектур ИНС, предназначенных для решения задачи семантической сегментации, значительная часть которых использует в своей основе свёрточные слои [1]. Среди наиболее часто используемых можно выделить FCN, DeepLab и U-net. Последняя изначально проектировалась для области биомедицины [2], но успешно показала себя и в других сферах: анализ спутниковых снимков [3], сейсмических данных [4] и, что наиболее важно в нашем случае, дефектов в различных материалах [5]. В качестве объекта исследований была выбрана именно архитектура U-net.

U-net состоит из двух логических частей: кодировщика и декодировщика. Кодировщик представляет собой типичную свёрточную ИНС: несколько блоков, состоящих из двух свёрточных слоёв  $3 \times 3$  с ReLU в качестве активационной функции и max-pooling-слоя для уменьшения размерности. При необходимости кодировщик может быть реализован более сложным образом. Блоки декодировщика состоят из “транспонированных свёрток”  $2 \times 2$  для увеличения размерности, конкатенации с выходными данными соответствующего блока кодировщика и обычных свёрток. Выходные данные всей сети формируются при помощи свёртки  $1 \times 1$ . Рисунок ниже иллюстрирует описанную архитектуру.




Рис. 4 - иллюстрация архитектуры U-net

Число блоков кодировщика в использованной модели, как и в описанной в статье [2], равно 5. С учётом аппаратных ограничений, число каналов на выходе каждого блока уменьшено в 4 раза.

Модель была реализована на языке программирования Python средствами модуля PyTorch с возможностью обучения на GPU.

### Генерация данных

Следующая задача состояла в создании обучающей выборки на основе предоставленных данных. Заказчиком были предоставлены фотографии продольных разрезов нефтепровода, размеченные экспертом, но количество изображений не было достаточным для обучения



модели. Поэтому потребовалось создать программу, выделяющую описанные дефекты с предоставленных фотографий и накладывающую их на изображение неповреждённого стального листа.

Реализован скрипт, выполняющий данную задачу и позволяющий выбрать тип и число накладываемых повреждений. Каждое повреждение описано в виде массива, содержащего координаты вершин многоугольника, ограничивающего повреждение. Выбранный многоугольник вырезается из нужного исходного изображения и накладывается на изображение “чистой” поверхности. Скрипт реализован на языке программирования Python с использованием модуля OpenCV.

Последующая работа с данными предполагает их аугментацию. Это позволяет дополнительно увеличить размер выборки и снизить риск переобучения. Традиционно используемые аугментации включают отражения, повороты, изменение яркости и контраста, наложение шумов. Все они были использованы.

Специфическая же задача состояла в том, чтобы сделать полученные данные более похожими на исходные. Так как предоставленные изображения представляют собой сегменты труб, часть их находится под углом к камере и не в фокусе. Искажение перспективы и размытие были выбраны для имитации этих особенностей. Пример предоставленного изображения, а также сгенерированного скриптом до и после аугментации представлен на рисунке 5.




Рис. 5 - пример генерации и аугментации

## Результаты тестирования

Модель была обучена на сгенерированных данных со следующими параметрами:

- 15 эпох;
- скорость обучения  $10^{-3}$ ;
- функция потерь - кросс-энтропия;
- оптимизатор Adam;
- отношение размеров обучающей и валидационной выборок 4:1.

На графиках 1-3 представлена динамика изменения величины потерь, точности и IoU в процессе обучения.




График 1 - зависимость величины потерь от эпохи

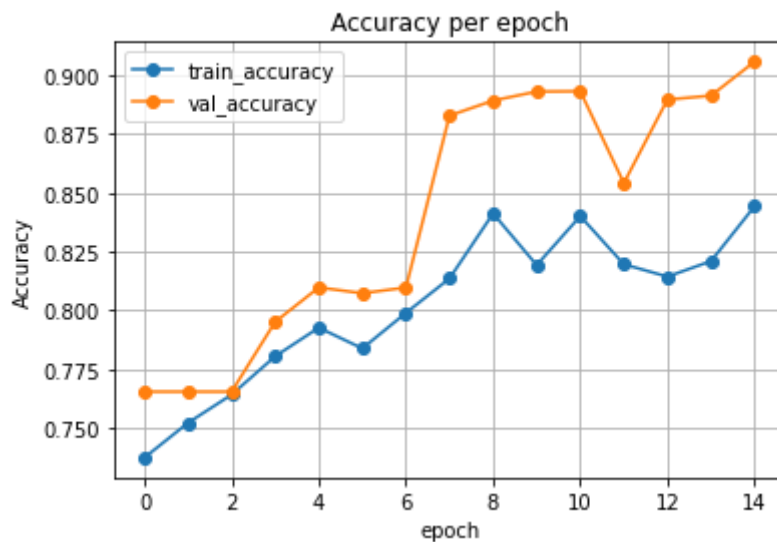


График 2 - зависимость точности от эпохи




График 3 - зависимость величины IoU от эпохи

Результаты обучения модели следующие:

- Точность на обучающей выборке 84%, на валидационной 91%;
- IoU на обучающей выборке 47%, на валидационной 66%.

Полученная точность превышает заявленную в постановке задачи на 16%. IoU на обучающей выборке на 3% ниже заявленной, но на всей выборке значение удовлетворительное.

## **Заключение**

Была поставлена задача разработки программного обеспечения анализа дефектов поверхности трубопровода по изображению. В ходе работы поставленная задача была решена.

Разработанное ПО соответствует поставленным требованиям к качеству выходных данных.

Значение IoU может быть повышено за счёт решения проблемы с распознаванием углублений.

Их небольшая относительная площадь и сходство с другими типами дефектов затрудняет получение хорошего результата. Дальнейшая работа над проектом будет направлена на решение этой проблемы.

## Список литературы

1. An overview of Semantic Segmentation Models // Papers with code  
<https://paperswithcode.com/methods/category/segmentation-models>
2. Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015, 234–241. doi:10.1007/978-3-319-24574-4\_28
3. McGlinchy, J., Johnson, B., Muller, B., Joseph, M., & Diaz, J. (2019). Application of UNet Fully Convolutional Neural Network to Impervious Surface Segmentation in Urban Environment from High Resolution Satellite Imagery. IGARSS 2019 - 2019 IEEE International Geoscience and Remote Sensing Symposium. doi:10.1109/igarss.2019.8900453
4. Abhilash Awasthi: Unet with simple ResNet blocks // Kaggle  
<https://www.kaggle.com/abhilashawasthi/unet-with-simple-resnet-blocks>
5. Kotyuzanskiy, L. A., Ryzhkova N. G., & Chetverkin N. V. (2020). Semantic segmentation in flaw detection. IOP Conf. Series: Materials Science and Engineering 862 (2020) 032056. doi:10.1088/1757-899X/862/3/032056